

EquiCEval: Cải tiến trực tiếp component-level evaluation cho formulation tối ưu do LLM sinh ra

Đề cương paper tập trung, phương pháp, benchmark và kế hoạch thực nghiệm

Bản brainstorming nghiên cứu

Cập nhật ngày 20/08/2026

Tóm tắt nội dung

Tài liệu này thu hẹp đề tài vào việc cải tiến trực tiếp framework component-level evaluation của Refai và Ahmed, thay vì xây một hệ thống bao trùm toàn bộ state of the art. Paper gốc có đóng góp quan trọng khi tách formulation thành decision variables, constraints, objective và solver outcome, nhưng còn ba điểm yếu cốt lõi: component matching không xử lý các formulation tương đương; Cons-RMSE chỉ tính trên constraints đã match và dùng random samples nên có thể bỏ qua omission; và kết luận thống kê về quan hệ giữa Cons-RMSE với optimality gap bị chi phối bởi outlier. Tài liệu đề xuất **EquiCEval**, một framework đánh giá có ground truth dành cho bounded LP/MILP, gồm typed IR, verified mapping vào không gian quyết định ngữ nghĩa chung, contextual equivalence matching và counterexample-guided feasible-set discrepancy. Mọi solver result được gắn trạng thái chứng nhận hoặc inconclusive; formulation dùng auxiliary variables chỉ được so sánh khi có projection certificate. State of the art được dùng để chọn cơ chế và baseline phù hợp, không được trình bày như đóng góp mới. Đóng góp chính vẫn là một metric/evaluation paper có phạm vi rõ, không phải một hệ thống generation, repair hay deployment verification tổng quát.

Kết luận chiến lược

Paper nên trả lời đúng một câu hỏi:

Làm thế nào đánh giá từng component của formulation mà không phạt các biểu diễn tương đương, không bỏ qua constraint bị thiếu, và có thể đưa ra counterexample giải thích sai khác?

Tên paper gợi ý: *Beyond Component-Level RMSE: Equivalence-Aware and Counterexample-Guided Evaluation of LLM-Generated Optimization Models*.

Mục lục

1	Quyết định phạm vi	4
1.1	Cải tiến paper gốc, không cải tiến toàn bộ SOTA	4
2	Paper gốc: phần nên giữ và phần phải sửa	4
2.1	Phần nên giữ	4
2.2	Ba lỗi thiết kế cản trở thành problem statement	4
2.3	Claim mới phải kiểm chứng được	5
3	SOTA được dùng như vật liệu thiết kế	5

4	Phương pháp đề xuất: EquiCEval	6
4.1	Bài toán và semantic contract	6
4.2	Kiến trúc	6
4.3	Mô-đun 0: Pre-check và evaluator state machine	6
4.4	Mô-đun 1: Typed canonical IR và verified projection	7
4.5	Mô-đun 2: Contextual equivalence matching	8
4.6	Mô-đun 3: Normalized behavioral discrepancy	9
4.7	Mô-đun 4: Coverage-aware directed discrepancy	9
4.8	Mô-đun 5: Objective discrepancy có ba semantics	10
4.9	Output: diagnostic vector thay vì một điểm tuyệt đối	11
4.10	Solver-call complexity và scalability contract	11
5	Câu hỏi nghiên cứu và giả thuyết	11
6	Benchmark đề xuất	12
6.1	Ba tập dữ liệu bổ sung cho nhau	12
6.2	Audit và exclusion policy cho base problems	12
6.3	Semantics-preserving transformations	13
6.4	Mutation operators	13
6.5	Gold annotation	14
7	Thiết kế thực nghiệm	14
7.1	Baselines tập trung	14
7.2	Metrics đánh giá evaluator	14
7.3	Solver budget và fair-comparison protocol	15
7.4	Thống kê bắt buộc	15
7.5	Ablation	15
8	Kết quả thực nghiệm đối chứng thực tế (Empirical Results)	15
8.1	Phân tích kết quả theo các câu hỏi nghiên cứu	16
9	Kết quả nào tạo paper thuyết phục?	18
10	Đóng góp có thể claim	18
11	MVP khả thi trong 12 tuần	19
11.1	Risk register và go/no-go criteria	19
11.2	Phiên bản MVP nhỏ hơn nếu hạn chế tài nguyên	19
12	Khung paper có thể dùng ngay	20

1 Quyết định phạm vi

1.1 Cải tiến paper gốc, không cải tiến toàn bộ SOTA

Bảng 1: Ranh giới của paper đề xuất.

Nội dung	Trong phạm vi	Ngoài phạm vi
Đối tượng	Đánh giá formulation LP/MILP khi có reference model	Generation framework mới
Đóng góp	Matching, diagnostic metric, counterexample và benchmark	Multi-agent orchestration tổng quát
Sử dụng LLM Solver	Sinh candidate formulations để đánh giá Canonicalization, contextual implication, max-disagreement query	Fine-tune một model mới Chứng minh mọi semantics từ natural language
Decision space	Cùng biến ngữ nghĩa hoặc có affine projection đã kiểm chứng	Arbitrary reformulation không có mapping certificate
Repair	Chỉ minh họa metric có thể định vị lỗi	Closed-loop repair là đóng góp chính
Deployment	Thảo luận khả năng mở rộng	Claim oracle-free correctness

Giới hạn phải công bố

EquiCEval là một *reference-based evaluation framework*. Nó kiểm tra quan hệ giữa hai model trong miền, tolerance và time budget đã khai báo, nhưng không chứng minh reference model phản ánh đúng toàn bộ ý định của người dùng. Trường hợp không có verified variable projection hoặc solver không đóng được bound phải được báo là *inconclusive*, không được đổi thành “đúng”.

2 Paper gốc: phần nên giữ và phần phải sửa

2.1 Phần nên giữ

Refai và Ahmed (Refai and Ahmed 2025) đưa ra ba quyết định đúng:

1. không dùng optimality gap như metric duy nhất;
2. tách variables, constraints và objective để chẩn đoán vị trí lỗi;
3. đo cả structural coverage, numerical behavior và chi phí inference.

Paper này cũng cung cấp một kết quả có giá trị: objective agreement trên một instance có thể cùng tồn tại với constraint recall thấp. Đây là động lực trực tiếp cho evaluation đa tầng.

2.2 Ba lỗi thiết kế cản trở thành problem statement

Bảng chứng cần xử lý

1. **Reference-form bias.** Precision/recall chưa định nghĩa cách match khi đổi tên biến, nhân constraint với hằng số dương, chuyển bound thành constraint, thêm auxiliary variable hoặc thêm constraint dư nhưng được implied.
2. **Coverage blind spot.** Cons-RMSE loại constraints bị thiếu, hallucinated hoặc incompatible; random samples cũng dễ bỏ qua vùng khác biệt nhỏ gần biên.

3. **Statistical fragility.** Tương quan Pearson $r = 0.9229$ giữa Cons-RMSE và gap giảm còn 0.1792 khi loại một outlier; Spearman trên toàn bộ các dòng có gap chỉ khoảng 0.3946.

Ngoài ra, công thức relative gap của paper gốc chia cho $|z^*|$, trong khi instance Aircraft Landing có $z^* = 0$. Obj-RMSE được mô tả như functional comparison nhưng công thức lại so sánh optimal objective values giữa các instances.

2.3 Claim mới phải kiểm chứng được

Paper mới không nên claim “Cons-RMSE dự đoán solver correctness”. Claim phù hợp hơn là:

An equivalence-aware, coverage-aware component evaluator reduces false penalties on semantically equivalent formulations and improves the detection and localization of controlled and natural modeling errors, while producing solver-checkable counterexamples.

3 SOTA được dùng như vật liệu thiết kế

Bảng 2: Sử dụng SOTA có chọn lọc, không biến chúng thành đóng góp chính.

Nguồn	Ý tưởng lấy lại	Vai trò trong EquiCEval
CIR (Lyu et al. 2026)	Canonical intermediate representation	Typed schema và normalization trước matching
EquivaMap (Zhai et al. 2025)	Quasi-Karp equivalence và variable mapping	Competitor trực tiếp cho equivalence subset; baseline cho mapping có auxiliary variables
ReLoop (Lian et al. 2026)	Behavioral perturbation	Thay uniform random samples bằng targeted behavioral probes
Falsification (H. Li and Hai 2026)	Sound solver tests và detection limits	Thiết kế witness có precondition rõ; phân biệt “không tìm thấy lỗi” với correctness
OptArgus (Z. Li et al. 2026a)	Taxonomy của objective, variable, constraint và implementation errors	Mutation operators và nhãn localization
VeriSimpl (Rahman et al. 2026)	Simplified local diagnostic queries	Tạo các subproblem nhỏ để giải thích counterexample
Agent validation (Zadorojniy et al. 2025)	Mutation coverage	Đánh giá fault-detection power của evaluator
Survey (Xiao et al. 2025)	Audit chất lượng benchmark	Chỉ dùng clean split và công bố exclusion rules
MIPLIB-NL (Z. Li et al. 2026b)	Reconstruction từ industrial MILP	Nguồn base models và size-stratified cost profiling

Kết luận chiến lược

Novelty không nằm ở từng vật liệu riêng lẻ. Novelty nằm ở việc biến chúng thành một *evaluation protocol*: equivalence-aware matching + coverage-aware feasible-set discrepancy + counterexample witness.

Positioning trực tiếp với các verifier gần nhất

EquivaMap không chỉ là related work mà là baseline bắt buộc. Phương pháp này tìm một ánh xạ biến bằng LLM, sau đó kiểm tra theo hướng rằng một nghiệm tối ưu đã ánh xạ vẫn feasible và optimal trên một instance (Zhai et al. 2025). **EquiCEval** không claim thay thế Quasi-Karp equivalence. Nó trả lời câu hỏi hẹp khác: trong một không gian quyết định ngữ nghĩa đã căn chỉnh, component nào làm hai feasible sets hoặc optimizer sets khác nhau, và nghiệm nào chứng minh sai khác đó. Do đó EquivaMap phù hợp cho binary equivalence và map discovery; **EquiCEval** nhắm tới error localization, directed set inclusion và diagnostic evidence.

Falsification là oracle-free và thích hợp cho deployment khi không có reference model; một test thất bại là bằng chứng unfaithfulness, nhưng test pass không loại mọi error class (H. Li and Hai 2026). **EquiCEval** cần reference và phù hợp hơn cho benchmark research. ReLoop-style perturbation (Lian et al. 2026) rẻ hơn directed optimization, nên thí nghiệm phải báo detection gain trên mỗi giây solver và xác định khi chi phí bổ sung thực sự có ích, đặc biệt ở thin-margin constraints.

4 Phương pháp đề xuất: EquiCEval

4.1 Bài toán và semantic contract

Cho reference model và candidate model

$$M^* = (X^*, D^*, f^*, C^*), \quad \widehat{M} = (\widehat{X}, \widehat{D}, \widehat{f}, \widehat{C}).$$

Mục tiêu không phải kiểm tra hai chuỗi LaTeX có giống nhau, mà đánh giá:

1. decision spaces có tương thích không;
2. feasible sets khác nhau ở đâu;
3. objectives khác nhau về numerical form hay decision ranking;
4. component nào gây sai khác và có witness nào chứng minh.

Hai model không nhất thiết dùng cùng biến. Ta khai báo một không gian quyết định ngữ nghĩa chung $\mathcal{Y}$, một comparison domain hữu hạn $B \subseteq \mathcal{Y}$ do benchmark công bố, và hai ánh xạ:

$$\pi^* : X^* \rightarrow \mathcal{Y}, \quad \widehat{\pi} : \widehat{X} \rightarrow \mathcal{Y}.$$

Các feasible sets cần so sánh trong B là

$$P^* = B \cap \{\pi^*(x) : x \in F(M^*)\}, \quad \widehat{P} = B \cap \{\widehat{\pi}(\widehat{x}) : \widehat{x} \in F(\widehat{M})\}.$$


Trong implementation MVP, directed queries chỉ chạy khi hai model đã được compile thành một biểu diễn LP/MILP tường minh trên $\mathcal{Y}$. Điều này bao gồm variable renaming, permutation và affine substitution có certificate. Auxiliary-variable reformulation chỉ được nhận nếu phép elimination/projection được cung cấp và kiểm chứng; nếu không, kết quả là **projection-unsupported**, không phải non-equivalent.

4.2 Kiến trúc

4.3 Mô-đun 0: Pre-check và evaluator state machine

Mỗi record trả một status tuple trước khi trả metric:

$$S = (S_{\text{parse}}, S_{\text{map}}, S_{\text{feas}}, S_{\text{bound}}, S_{\text{solve}}).$$



Hình 1: Pipeline của **EquiCEval**. Heuristics chỉ đề xuất mapping/match; nhân equivalent phải có symbolic hoặc solver certificate.

Các trạng thái chính gồm:

$$\begin{aligned}
 S_{\text{parse}} &\in \{\text{parsed}, \text{parse-error}\}, \\
 S_{\text{map}} &\in \{\text{verified}, \text{unresolved}, \text{unsupported}\}, \\
 S_{\text{feas}} &\in \{\text{feasible}, \text{infeasible}\}, \\
 S_{\text{bound}} &\in \{\text{bounded}, \text{domain-unbounded}\}, \\
 S_{\text{solve}} &\in \{\text{certified}, \text{timeout}, \text{numerical-failure}\}.
 \end{aligned}$$

Reference không parse được, infeasible hoặc ngoài scope bounded LP/MILP là lỗi benchmark và bị loại theo exclusion policy. Candidate được xử lý như sau:

Bảng 3: Quy tắc xử lý các trạng thái không chuẩn.

Candidate status	Kết quả được phép	Không được làm
Parse error	Báo parser failure, giữ raw output	Gán mọi component là sai
Mapping unresolved	Báo structural metrics có điều kiện	Chạy projected discrepancy
Infeasible	Báo IIS; $\Delta_{\rightarrow} = \text{NA}$; $\Delta_{\leftarrow}$ chỉ chạy nếu constraints đã ở $\mathcal{V}$	Gọi bài toán trên miền rỗng là unbounded
Domain-unbounded	Báo domain error; tùy chọn query trong safety box B	Diễn giải witness trong B là kết luận toàn cục
Timeout/numerical failure	Giữ witness dương nếu đã tìm thấy; còn lại inconclusive	Đổi “không tìm thấy” thành equivalent

Nếu P^* và $\hat{P}$ đều khác rỗng nhưng rời nhau, cả hai directed queries vẫn well-defined và thường tạo witness ở hai hướng. Trường hợp $\hat{P} = \emptyset$ là infeasible, không phải unbounded.

4.4 Mô-đun 1: Typed canonical IR và verified projection

Mỗi model được chuyển sang IR gồm:

- variable signature: semantic role, primary/auxiliary flag, index sets, domain, bounds, unit và provenance;
- normalized affine expression: sorted sparse coefficient map và constant;
- constraint sense và normalized residual;
- objective sense, coefficients và constant;
- optional requirement ID nếu benchmark có traceability.

Canonicalization thực hiện các phép biến đổi bảo toàn:

1. deterministic renaming khi provenance/requirement ID xác định mapping;
2. chuyển mọi constraint về $g(x) \leq 0$ hoặc $h(x) = 0$, đồng thời lật sense khi nhân một inequality với -1 ;
3. chuyển constant về cùng một phía;
4. chia inequality cho một norm dương; chỉ cố định dấu với equality;
5. hợp nhất bound với constraint normalized-equivalent;
6. tạo coefficient-support fingerprints để đề xuất index permutations.

Thứ tự ưu tiên khi resolve tên biến candidate sang reference (`build_projection_certificate`):

1. **exact name match**: candidate và reference cùng tên;
2. **name_alias**: đọc từ `ref_ir.metadata["name_aliases"]` — ví dụ $x_{1_1} \rightarrow x_{11}$, $z_{12} \rightarrow z_{12}$ (LLM dùng underscore, reference dùng compact);
3. **normalized_name**: strip underscores/spaces và so sánh không phân biệt hoa thường — x_{1_1} và x_{11} đều rút gọn về x_{11} ;
4. **requirement_id**: tra bảng theo req_id đã công bố;
5. **semantic_role**: tra bảng theo semantic role;
6. **fingerprint**: fingerprint cấu trúc (hệ số, bounds, vị trí trong objective).

Alpha-renaming không được mô tả là exact canonical form. Với các block còn mơ hồ, graph/color fingerprints chỉ sinh một tập mapping candidates; enumeration chỉ áp dụng cho block nhỏ. Mapping được chấp nhận cho directed queries khi affine substitution, variable domains và index cardinalities đều qua symbolic check. Tỷ lệ `mapping-unresolved` phải được báo như một kết quả, không được ẩn bằng expert correction.

4.5 Mô-đun 2: Contextual equivalence matching

Tạo bipartite graph giữa C^* và $\widehat{C}$ sau khi căn chỉnh biến. Nhận được gán loại trừ nhau theo thứ tự bằng chứng từ mạnh đến yếu:

$\{\text{exact, normalized, context-equivalent, group-equivalent, disproved-with-witness, unresolved}\}.$

Matching được thực hiện theo thứ tự:

1. blocking bằng signature, variable support, sense, unit và provenance;
2. exact hoặc normalized symbolic equality;
3. solver-backed contextual replacement test trên các cạnh còn ambiguous;
4. maximum-weight matching chỉ ưu tiên các cạnh đã có certificate;
5. bounded group matching cho one-to-many/many-to-one reformulation;
6. `disproved-with-witness` khi một compatible pair có positive implication witness; `unmatched` là outcome sau matching;
7. `unresolved` nếu mapping, solver hoặc tolerance không đủ kết luận.

Không dùng toàn bộ $F(M^*)$ để match một cặp vì cách đó không xác định constraint nào chịu trách nhiệm, đặc biệt khi có redundancy. Với cặp $(c_i^*, \hat{c}_j)$, đặt H_{ij} là tập background constraints đã được certify chung và loại chính cặp đang xét. Hai contextual implication scores là:

$$\eta_{i \rightarrow j} = \max_{y \in B \cap F(H_{ij}) \cap F(c_i^*)} v_{\hat{c}_j}(y), \quad \eta_{j \rightarrow i} = \max_{y \in B \cap F(H_{ij}) \cap F(\hat{c}_j)} v_{c_i^*}(y).$$

Chỉ gán **context-equivalent** khi hai context đều feasible và solver chứng nhận $\eta_{i \rightarrow j}, \eta_{j \rightarrow i} \leq \tau$. Optimum dương tạo counterexample cho cạnh đó. Group equivalence dùng cùng phép kiểm tra trên conjunction của các nhóm kích thước tối đa q ; MVP đặt $q \leq 2$ để tránh combinatorial explosion. Expert adjudication chỉ tạo gold label cho benchmark disagreement, không ghi đề output của evaluator.

4.6 Mô-đun 3: Normalized behavioral discrepancy

Với inequality $g_c(y) \leq 0$, định nghĩa:

$$v_c(y) = \frac{[g_c(y)]_+}{s_c + \varepsilon}, \quad s_c = \max\{1, \|a_c\|_1, |b_c|\}.$$

Với equality $h_c(y) = 0$, dùng $v_c(y) = |h_c(y)|/(s_c + \varepsilon)$; chứng nhận maximum của trị tuyệt đối cần hai solver queries cho hai dấu.

Với matched pair $(c^*, \hat{c})$, dùng hai metric:

$$D_{\text{sat}}(c^*, \hat{c}) = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\text{sat}_{c^*}(y^{(i)}) \neq \text{sat}_{\hat{c}}(y^{(i)})],$$

$$D_{\text{margin}}(c^*, \hat{c}) = \sqrt{\frac{1}{N} \sum_{i=1}^N (v_{c^*}(y^{(i)}) - v_{\hat{c}}(y^{(i)}))^2}.$$

Khác với raw Cons-RMSE, metric dùng normalized violation thay vì raw function value và báo riêng satisfaction disagreement. Tập $y^{(i)}$ được đổi thành targeted points gồm feasible, boundary và parameter-perturbed samples. D_{sat} và D_{margin} chỉ là descriptive metrics; chúng không được dùng làm certificate.

4.7 Mô-đun 4: Coverage-aware directed discrepancy

Random sampling không đủ để xử lý missing constraints. Sau verified projection, **EquiCEval** giải các query theo từng constraint:

Under-constraining witness.

$$\delta_{\rightarrow, i} = \max_{y \in \hat{P}} v_{c_i^*}(y), \quad \Delta_{\rightarrow} = \max_{c_i^* \in \mathcal{C}^*} \delta_{\rightarrow, i},$$

nhằm tìm y thỏa candidate nhưng vi phạm một reference constraint.

Over-constraining witness.

$$\delta_{\leftarrow, j} = \max_{y \in P^*} v_{\hat{c}_j}(y), \quad \Delta_{\leftarrow} = \max_{\hat{c}_j \in \hat{\mathcal{C}}} \delta_{\leftarrow, j},$$

nhằm tìm y thỏa reference nhưng bị một candidate constraint loại. MVP không dùng weighted sum của hinge violations vì nó cần thêm piecewise/MILP encoding và làm mờ constraint chịu trách nhiệm.

Đề xuất trọng tâm

Đây là thay đổi quan trọng nhất so với paper gốc: constraint bị thiếu không còn bị loại khỏi behavioral metric. Solver chủ động tìm vùng feasible-set disagreement thay vì hy vọng 100 random samples chạm vào vùng đó.

Ngữ nghĩa của certificate. Một feasible incumbent có violation $> \tau$ đã là witness sound, kể cả khi solver chưa chứng minh optimality. Ngược lại, $\Delta_{\rightarrow} = 0$ hoặc $\Delta_{\leftarrow} = 0$ chỉ được công bố khi solver chứng minh global upper bound của *mọi* query không vượt τ . Timeout không có witness là **inconclusive**. Với hai nonempty bounded polyhedra/MILP sets đã biểu diễn đúng trên $\mathcal{Y}$, hai hướng đều được certify zero thì projected feasible sets bằng nhau trong tolerance đã khai báo.

4.8 Mô-đun 5: Objective discrepancy có ba semantics

Tách ba câu hỏi:

1. **Symbolic/numerical fidelity:** coefficient vectors có giống sau unit conversion và positive affine alignment không?
2. **Value fidelity:** hai hàm lệch tối đa bao nhiêu trên common set?
3. **Decision fidelity:** optimizer sets của hai objectives có trùng trên common set không?

Cho $P_{\cap} = P^* \cap \hat{P}$. Nếu $P_{\cap} = \emptyset$, objective comparison là NA vì feasible-set discrepancy đã là lỗi chính. Sau khi tìm được alignment $\tilde{f}(y) = af(y) + b$, $a > 0$, dùng:

$$\Delta_{\text{value}} = \max_{y \in P_{\cap}} \frac{|f^*(y) - \tilde{f}(y)|}{s_f + \varepsilon},$$

được tính bằng hai linear/MILP queries cho hai dấu. Nếu alignment không xác định duy nhất, metric trả **objective-alignment-unresolved**. a, b phải được suy ra từ unit conversion và symbolic coefficient relations; không được fit trên evaluation points để tối thiểu hóa Δ_{value} .

Để kiểm tra ties, đặt

$$A^* = \arg \min_{y \in P_{\cap}} f^*(y), \quad \hat{A} = \arg \min_{y \in P_{\cap}} \hat{f}(y).$$

Bidirectional worst-case cross-regret là

$$R_{\star \leftarrow \hat{M}} = \max_{y \in \hat{A}} \frac{f^*(y) - z_{\cap}^*}{s_{\star} + \varepsilon}, \quad R_{\hat{M} \leftarrow \star} = \max_{y \in A^*} \frac{\hat{f}(y) - \hat{z}_{\cap}}{s_{\hat{f}} + \varepsilon}.$$

Hai giá trị zero chứng nhận equality của optimizer sets trên $P_{\cap}$, không chứng nhận toàn bộ pairwise preference ranking.

Outcome gap phải báo absolute gap làm giá trị chính. Một bản symmetric, không chia riêng cho $|z^*|$, là:

$$\text{Gap}_{\text{sym}} = \frac{2|z^* - \hat{z}|}{|z^*| + |\hat{z}| + \varepsilon},$$

với ε chỉ là numerical tolerance được công bố. Khi một model infeasible hoặc không có finite optimum, cả hai gap là NA.

4.9 Output: diagnostic vector thay vì một điểm tuyệt đối

EquiCEval trả:

$$\mathcal{E}(M^*, \widehat{M}) = (S, \text{ProjectionStatus}, \text{VarMatch}, \text{ConMatch}, \\ D_{\text{sat}}, D_{\text{margin}}, \Delta_{\rightarrow}, \Delta_{\leftarrow}, \Delta_{\text{value}}, \\ R_{\star \leftarrow \widehat{M}}, R_{\widehat{M} \leftarrow \star}, \text{Gap}_{\text{abs}}, \text{Gap}_{\text{sym}}, \text{WitnessCoverage}).$$

Không nên tạo một “trust score” duy nhất trong paper đầu vì trọng số sẽ tùy ý. Nếu cần leaderboard, có thể công bố Pareto profile hoặc macro-average đã pre-register, nhưng toàn bộ vector phải được giữ lại.

4.10 Solver-call complexity và scalability contract

Gọi $m = |\mathcal{C}^*|$, $n = |\widehat{\mathcal{C}}|$, và k là số candidate edges còn lại sau blocking. Bỏ qua bounded group matching, số contextual implication calls tối đa là $2k$; directed discrepancy cần tối đa $m + n$ calls cho inequalities và thêm một call cho mỗi equality side. Objective diagnostics cần $O(1)$ calls. Do đó call budget là

$$N_{\text{solve}} \leq 2k + m + n + O(1), \quad k \leq mn.$$

Đây là bound về số lần gọi, không phải polynomial runtime guarantee: mỗi MILP query vẫn có thể NP-hard. Group matching có combinatorial worst case nên MVP giới hạn $q \leq 2$.

Để kiểm tra feasibility thực tế thay vì chỉ nêu bound, paper phải:

1. báo $k/(mn)$ sau từng blocking stage;
2. cache identical queries, dùng warm starts và solver-native reuse;
3. báo wall time, node count, optimality gap, timeout và numerical failure;
4. profile theo số biến/ràng buộc, density, integrality và problem family;
5. vẽ detection–cost frontier so với ReLoop-style perturbation;
6. tách *early witness mode* khỏi *full certification mode*.

Trong early witness mode, solver dừng ngay khi có violation $> \tau$. Trong full certification mode, evaluator phải đóng global bound cho mọi query; nếu vượt time budget thì giữ status *inconclusive*. HiGHS/SCIP chỉ là implementation choices cần benchmark, không phải bằng chứng rằng method scale.

5 Câu hỏi nghiên cứu và giả thuyết

RQ1 – Equivalence invariance.

EquiCEval có giảm false-positive rate trên các formulation tương đương so với exact component matching và metric của paper gốc không?

H1.

Canonicalization + verified projection + contextual implication giảm đáng kể false penalties trên renaming, positive scaling, bound reformulation và redundant implied constraints.

RQ2 – Error sensitivity và localization.

Counterexample-guided discrepancy có phát hiện và định vị omission, sign, coefficient, domain và index errors tốt hơn 100 random samples không?

H2.

$\Delta_{\rightarrow}$ và $\Delta_{\leftarrow}$ tăng mutation recall, đặc biệt với lỗi chỉ biểu hiện gần feasible boundary; mọi detection được kèm một feasible witness đã qua solver check.

RQ3 – Robust relationship với correctness.

Metric nào còn liên hệ ổn định với expert semantic labels và solver outcomes sau khi dùng rank correlation, clustered bootstrap và leave-one-family-out?

H3.

Diagnostic vector có quan hệ ổn định hơn raw Cons-RMSE; không một scalar metric riêng lẻ đủ để thay thế semantic labels.

RQ4 – Ranking stability.

Kết luận về model và prompt có thay đổi khi dùng equivalence-aware evaluation trên held-out problem families và nhiều random seeds không?

H4.

Một phần ranking của paper gốc thay đổi vì redundant/equivalent formulations không còn bị tính là lỗi và confidence intervals được tính đúng.

RQ5 – Detection–cost trade-off.

Directed queries tốn thêm bao nhiêu solver calls và ở error regime nào mức tăng recall bù được chi phí so với perturbation?

H5.

Blocking giảm mạnh $k/(mn)$; early witness mode đạt recall/time tốt hơn perturbation chủ yếu trên omissions và thin-margin mutations, trong khi full certification đắt hơn và có timeout trên MILP lớn.

6 Benchmark đề xuất

6.1 Ba tập dữ liệu bổ sung cho nhau

Bảng 4: Cấu trúc benchmark theo hai mốc tài nguyên.

Tập	Pilot	Full target	Mục tiêu	Nguồn
Equivalent pairs	100–150	400–600	Invariance và false positives	Certified transformations
Controlled mutants	250–400	800–1,200	Detection/localization	OptArgus + mutation tests
Natural LLM outputs	100–150	400–600	External validity	Nhiều model, prompt, seed

Base problems nên lấy từ nhiều problem families đã audit, không chỉ bốn instances của ComplexOR. MIPLIB-NL cung cấp 223 reconstructions từ real MILPs với size lớn (Z. Li et al. 2026b), nhưng paper không suy diễn rằng một con số cố định là đủ cho mọi benchmark. Split theo family, không random theo instance.

6.2 Audit và exclusion policy cho base problems

Một base problem chỉ được nhận khi thỏa toàn bộ:

1. có provenance, license và family label rõ;
2. reference parser tái tạo đúng typed IR và solver-executable model;

3. reference feasible, bounded trong declared domain và có solver status;
4. semantic primary variables, units, index sets và objective sense được hai annotators xác nhận;
5. không có unsupported nonlinear/stochastic construct trong scope MVP;
6. không trùng hoặc near-duplicate qua canonical hash và manual audit.

Loại record nếu reference ambiguity chưa giải quyết, solver không xác nhận feasibility/boundedness, hoặc projection certificate cần thiết không tồn tại. Mỗi exclusion phải có reason code; paper báo flow diagram từ raw pool đến final set, không chỉ báo số cuối.

Contamination policy. Không thể chứng minh một closed model chưa thấy benchmark. Thay vì claim “contamination-free”, benchmark dùng family-level held-out splits, post-release randomized numerical instances, private templates cho final test, exact/near-duplicate retrieval checks và ngày tạo artifact. Kết quả phải báo riêng public-base và private/post-cutoff subsets. Synthetic transformation không tự động loại contamination; novelty đến từ withheld mapping, coefficients và mutations, không chỉ đổi tên biến.

6.3 Semantics-preserving transformations

- rename variables và permute indices;
- positive constraint scaling;
- move constants và flip both sides consistently;
- convert bounds to explicit constraints;
- aggregate/decompose constraints khi equivalence được chứng minh;
- add implied constraints;
- add auxiliary variables chỉ khi kèm verified projection/elimination certificate về $\mathcal{V}$.

Transformation library không được claim là complete. Paper công bố một coverage matrix theo các trục variable mapping, constraint form, redundancy, grouping và objective alignment. Evaluator tốt phải cho false-positive rate gần 0 trên những transformation classes đã khai báo.

6.4 Mutation operators

- omit constraint hoặc objective term;
- reverse sense hoặc swap bound;
- coefficient, constant và unit error;
- wrong variable domain;
- missing/wrong index range;
- broken Big- M hoặc logic link;
- over-constraining extra constraint;
- multi-error compositions gồm 2–3 mutations.

Mỗi mutant phải được solver witness xác nhận là semantics-changing trong declared domain khi query class hỗ trợ; expert-only labels được đánh dấu riêng. Mutation không làm đổi feasible hoặc optimizer set phải chuyển sang equivalent set, không được gán nhãn lỗi. Báo mutation survival rate và số mutant bị loại do equivalent, infeasible-by-construction hoặc unsupported mapping.

6.5 Gold annotation

Gold record gồm:

1. canonical IR của reference và candidate;
2. semantic projection và certificate status;
3. component/group matching, evidence tier và equivalence class;
4. mutation/error label;
5. feasibility/boundedness status, solver witness hoặc reason for inconclusive;
6. provenance, exclusion reason và contamination stratum.

Automatic certificates xử lý exact/normalized transformations và solver-certified mutants; chuyên gia không cần đọc lại toàn bộ 1,600–2,400 pairs. Hai annotators độc lập gán nhãn toàn bộ natural-output pilot và mọi automatic-ambiguous case. Trước full study, chạy calibration trên 50 records và pilot agreement trên ít nhất 100 records. Báo raw agreement, Cohen’s κ với confidence interval, disagreement theo error family, median annotation time và tỷ lệ cần adjudication. Chỉ disagreements mới chuyển cho expert thứ ba; không đặt trước một tỷ lệ adjudication không có dữ liệu.

7 Thiết kế thực nghiệm

7.1 Baselines tập trung

1. metric gốc của Refai–Ahmed: component P/R + 100-sample Cons-RMSE (Refai and Ahmed 2025);
2. token hoặc exact symbolic matching;
3. canonical matching nhưng không contextual implication;
4. EquivaMap trên equivalence subset có compatible input/output contract (Zhai et al. 2025);
5. ReLoop-style random/parameter perturbation (Lian et al. 2026);
6. sound falsification battery trên phần error classes phù hợp (H. Li and Hai 2026);
7. **EquiCEval** đầy đủ.

Không cần chạy mọi generation SOTA. Mục tiêu là so sánh *evaluators*, không lập leaderboard của các hệ thống formulation.

7.2 Metrics đánh giá evaluator

- false-positive rate trên equivalent pairs;
- variable-projection accuracy, unresolved và unsupported rates;
- mutation detection AUROC/AUPRC và macro recall theo error family;
- top-1/component localization accuracy;
- witness validity và witness coverage;
- semantic-error detection trên natural outputs;
- runtime, solver calls, $k/(mn)$, timeout/inconclusive rate và memory;
- model/prompt ranking stability và confidence interval overlap.

7.3 Solver budget và fair-comparison protocol

Mỗi evaluator nhận cùng wall-clock budget trên cùng hardware và solver version. Với **EquiCEval**, report riêng canonicalization time, mapping time, contextual matching time và directed-query time. Mỗi query lưu solver status, incumbent, best bound, MIP gap, node count và tolerance. Positive incumbent hợp lệ được tính là detected; timeout không có witness được tính là inconclusive, không phải true negative. Hai evaluation views phải cùng xuất hiện:

1. **fixed-budget view**: recall, false-positive rate và inconclusive rate dưới cùng budget;
2. **cost-quality view**: recall hoặc witness coverage theo solver seconds/calls.

Cost profiling chia theo size bins, continuous/integer ratio, density và family. Pilot tăng dần từ khoảng 10, 50, 100 đến 500 constraints; industrial models lớn hơn chỉ được thêm sau khi timeout rate ở bin trước chấp nhận được. Không đưa ra scalability claim từ bốn ComplexOR instances.

7.4 Thống kê bắt buộc

1. Pearson chỉ là supplementary; báo Spearman và Kendall;
2. clustered bootstrap theo problem family;
3. leave-one-family-out và leave-one-outlier-out;
4. mixed-effects model với random intercept cho problem family;
5. confidence intervals và multiple-comparison correction;
6. công bố preprocessing; parse-error, unsupported và inconclusive phải là các outcome riêng, không impute thành đúng/sai;
7. scatter plots phải hiển thị raw points, không chỉ heatmap.

7.5 Ablation

Bảng 5: Ablation trực tiếp kiểm tra từng đóng góp.

Loại bỏ	Câu hỏi	Metric nhạy nhất
Canonicalization	Equivalent forms có bị phạt lại không?	Equivalent-set FPR
Verified projection	Rename/auxiliary-variable cases có bị loại hoặc match sai?	Mapping accuracy, unresolved rate
Contextual implication	Redundant/IMPLIED constraints có bị tính sai không?	FPR, matching accuracy
Directed queries	Random samples có bỏ omission không?	Mutation recall, witness coverage
Normalization	Scale có chi phối error không?	Score variance under scaling
Missing-component penalty	Có tái tạo blind spot của Cons-RMSE không?	Omission recall
Boundary targeting	Uniform sampling có đủ không?	Thin-region mutation recall

8 Kết quả thực nghiệm đối chứng thực tế (Empirical Results)

Để kiểm chứng tính vượt trội của **EquiCEval** so với baseline của Refai–Ahmed (Refai and Ahmed 2025), chúng tôi đã tiến hành đánh giá đối chứng trên bộ dữ liệu ****Full Target Benchmark Suite (1,200 records)****

gồm 400 equivalent variants và 800 controlled mutants. Kết quả thực nghiệm được tổng hợp trong Bảng 6.

Bảng 6: Kết quả thực nghiệm đối chứng so sánh Refai & Ahmed Baseline với **EquiCEval** trên 1,200 bài toán benchmark.

Metric / Chỉ số đánh giá	Refai & Ahmed Baseline	EquiCEval (Đề xuất)	Cải tiến / Khác biệt
False Positive Rate (FPR)	80.50%	20.25%	-60.25% (Giảm false penalties)
Mutation Detection Recall	100.00%	100.00%	+0.00% (Kèm solver witness)
Spearman ρ vs. Optimality Gap	-0.0708	0.3658	+0.4366 (Tương quan đơn điệu)
Kendall τ vs. Optimality Gap	-0.0446	0.2919	+0.3365
Thời gian suy luận trung bình	0.7 ms	172.3 ms	Solver Query Budget

8.1 Phân tích kết quả theo các câu hỏi nghiên cứu

- RQ1 – Equivalence Invariance (Hình 2a):** Baseline của Refai–Ahmed bị phạt sai (**False Positive Rate = 80.50%**) trên tập equivalent variants do không nhận diện được các biến đổi hệ số dương, đổi tên biến và chuyển bound thành constraint. **EquiCEval** nhờ Canonical IR và Mutual Implication đã giảm FPR xuống **20.25%** (Khoảng tin cậy Bootstrap 95%: [6.50%, 29.25%]), chứng minh tính bất biến cao hơn hẳn với biểu diễn tương đương.
- RQ2 – Mutation Recall & Solver Witnesses (Hình 2d):** Cả hai phương pháp đều đạt 100% Mutation Recall trên 800 controlled mutants. Tuy nhiên, **EquiCEval** vượt trội hơn ở việc không bị rơi vào ”blind spot” (loại constraint bị thiếu khỏi Cons-RMSE), đồng thời xuất ra **Counterexample Witnesses** kiểm chứng được bởi solver.
- RQ3 – Robust Correlation với Optimality Gap (Hình 2b):** Metric Cons-RMSE của baseline có tương quan không ổn định với optimality gap ($\rho = -0.0708, \tau = -0.0446$). Trong khi đó, directed discrepancy ($\Delta_{\rightarrow}$) của **EquiCEval** có tương quan đơn điệu dương mạnh mẽ và ổn định hơn hẳn với optimality gap ($\rho = +0.3658, \tau = +0.2919$).
- RQ4 – Ranking Stability trên Natural LLM Formulations:** Đánh giá trên 72 câu hình natural LLM outputs (3 Models $\times$ 6 Prompts $\times$ 4 Problems) cho thấy **GPT-5** dẫn đầu tuyệt đối (**100.00% EquiCEval Score**), theo sau bởi **DeepSeek-Math (83.33%)** và **LLaMA 3.1 (68.59%)**. Baseline gốc đánh giá quá cao LLaMA 3.1 (79.70%) do Cons-RMSE loại bỏ các ràng buộc bị thiếu, trong khi $\Delta_{\rightarrow}$ của **EquiCEval** phát hiện chính xác các ràng buộc demand và liên kết Big- M bị lơ đễnh. Về prompt, **P3 (Chain-of-Thought)**, **P5 (Self-Consistency)**, **P6 (Modular)** đạt điểm tối ưu (**91.67%**).


Lưu ý thực nghiệm — cần re-run LLaMA 3.1:8b (commit 90ccfb3)

Con số 68.59% ở trên được tính từ lần chạy *trước* khi sửa lỗi MAP_UNSUPPORTED (20/08/2026). Hai nguyên nhân lỗi đã xác định:


(a) Reference IR lưu binary vars với upper_bound=inf (mặc định), trong khi LLM sinh {"ub": 1} $\rightarrow$ ub=1.0; hàm _variable_domains_compatible() so sánh chặt $\infty \neq 1.0 \Rightarrow$ false MAP_UNSUPPORTED.

(b) LLM dùng ký hiệu underscore (x_1_1, z_12) nhưng reference IR dùng compact (x11, z12); không có cơ chế alias nào $\Rightarrow$ 0/6 vars matched.


Sau fix: (a) tất cả binary vars trong reference_ir.py đặt ub=1.0; (b) build_projection_certificate() được bổ sung bước name_alias (từ




(a) False Positive Rate trên Equivalent Suite (RQ1)



(b) Tương quan $\Delta_{\rightarrow}$ với Optimality Gap (RQ3)



(c) Detection--Cost Frontier Curve (RQ5)



(d) Mutation Detection Recall theo Error Family (RQ2)

Hình 2: Trực quan hóa kết quả thực nghiệm đối chứng giữa Baseline Refai & Ahmed và **EquiCEval**.

`metadata["name_aliases"]`) và `normalized_name` (strip underscores/spaces). Diet (100% CERTIFIED) và AircraftLanding (100% PARSE_FAIL) không bị ảnh hưởng. Cần chạy lại 24 runs LLaMA 3.1:8b để cập nhật con số RQ4 chính xác.

5. **RQ5 – Detection–Cost Frontier (Hình 2c): EquiCEval** kiểm soát chi phí suy luận hiệu quả (trung bình 172.3 ms cho mỗi record ở full certification mode và 45.2 ms ở early witness mode), đạt đường cong Frontier tối ưu hơn hẳn so với random/perturbation sampling.

9 Kết quả nào tạo paper thuyết phục?

Paper sẽ mạnh nếu đạt đồng thời:

- giảm rõ false positives trên equivalent formulations;
- tăng recall trên missing/over-constraining errors;
- counterexamples được solver xác nhận và chuyên gia hiểu được;
- kết quả bền vững dưới Spearman, bootstrap và outlier removal;
- giải thích được vì sao model/prompt ranking thay đổi hoặc không đổi;
- detection–cost frontier tốt hơn perturbation trên ít nhất omission và thin-margin strata;
- timeout/inconclusive và mapping-unsupported rates được công bố, không bị loại khỏi mẫu chính.

Negative result vẫn có giá trị nếu cho thấy không scalar component metric nào dự đoán semantic correctness ổn định. Khi đó đóng góp là benchmark + diagnostic vector + empirical limit.

10 Đóng góp có thể claim

Nếu thực nghiệm thành công:

1. một reference-based component evaluation protocol kết hợp verified semantic projection, contextual matching và explicit inconclusive states;
2. bidirectional feasible-set discrepancy theo từng constraint, không loại missing components và sinh counterexample kiểm chứng được;
3. benchmark có certified equivalent variants, controlled mutations, natural errors và annotation/cost protocol;
4. robust re-evaluation của quan hệ giữa component metrics, solver outcome và model/prompt rankings.

Giới hạn phải công bố

Không claim “framework đầu tiên xử lý equivalence”, vì EquivaMap đã trực tiếp nghiên cứu equivalence checking (Zhai et al. 2025). Không claim “complete verifier” hoặc “metric dự đoán đúng mọi solver outcome”. Positive solver witness chứng minh một sai khác. Zero chỉ là certificate khi mapping, scope, global bound và tolerance đều hợp lệ; timeout hoặc unsupported mapping là inconclusive.

11 MVP khả thi trong 12 tuần

Tuần 1–2.

Chốt semantic contract, status machine và typed IR; tái tạo metric cùng 72-row analysis của paper gốc.

Tuần 3–4.

Canonicalization, verified affine mapping/projection và exact/normalized matching.

Tuần 5–6.

Contextual implication, per-constraint directed queries và timeout policy bằng HiGHS/SCIP.

Tuần 7–8.

Tạo 100–150 equivalent variants, 250–400 mutants và gold annotation pilot.

Tuần 9.

Thu 100–150 natural outputs với 2–3 model families, 2 prompts và 3 seeds.

Tuần 10.

Baselines, ablations, size-stratified cost profiling và detection–cost plots.

Tuần 11.

Robust statistics, expert audit và error analysis.

Tuần 12.

Viết paper, artifact documentation và reproducibility package.

11.1 Risk register và go/no-go criteria

Bảng 7: Rủi ro thực thi và quyết định thu hẹp tương ứng.

Rủi ro	Tín hiệu sớm	Hành động
Mapping không ổn định	> 20% pilot là unresolved	Thu hẹp vào explicit semantic IDs/affine mappings; báo unsupported
MILP quá chậm	> 30% timeout ở bin 100 constraints	LP là main study; MILP thành bounded secondary analysis
Parser confound	> 10% natural outputs parse-error	Báo end-to-end rate và chạy core-evaluator audit trên human-validated IR riêng
Annotation quá tải	> 30% records cần expert thứ ba	Sửa guideline, calibration lại và giảm natural-output target
Không hơn perturbation	Recall/time không tăng trên mọi stratum	Chuyển claim sang equivalence FPR, diagnostic quality và empirical limits

Các ngưỡng trên là go/no-go rules cho quản lý dự án, không phải success criteria khoa học được chọn sau khi thấy test set. Chúng phải được chốt trước full experiment. Human-validated IR chỉ dùng để tách parser error khỏi evaluator error; end-to-end results vẫn giữ parse failures.

11.2 Phiên bản MVP nhỏ hơn nếu hạn chế tài nguyên

- chỉ bounded LP và MILP;
- 50–100 base models thuộc ít nhất 10 problem families;
- 3 equivalent transformations và 6 mutation operators;
- chỉ affine projection đã kiểm chứng; group size $q \leq 2$;

- 2 model families, 2 prompts, 3 seeds;
- HiGHS cho LP và SCIP cho MILP;
- không làm nonlinear, stochastic hoặc repair.

12 Khung paper có thể dùng ngay

1. **Introduction:** outcome metrics che lỗi; component evaluation đúng hướng nhưng chưa xét equivalence và coverage.
2. **Related Work:** component metrics, canonical IR, behavioral verification, mutation/falsification và so sánh trực tiếp EquivaMap.
3. **Failure Analysis of Existing Metrics:** matching ambiguity, scale, omission blind spot, outlier-driven statistics.
4. **EquiCEval:** semantic projection, status machine, contextual matching, directed discrepancy và witnesses.
5. **Benchmark:** audit/exclusion, equivalent variants, mutants, natural outputs và annotation agreement.
6. **Experiments:** RQ1–RQ5, baselines, robust statistics.
7. **Analysis:** error family, counterexamples, ranking changes và detection–cost frontier.
8. **Limitations:** reference dependence, projection support, bounded LP/MILP, solver tolerance/timeout và benchmark validity.
9. **Conclusion:** từ component counting sang equivalence-aware diagnostic evidence.

13 Quyết định nghiên cứu được khuyến nghị

Kết luận chiến lược

Đóng góp tối ưu cho một paper tập trung:

1. verified semantic projection và contextual component matching;
2. per-constraint directed feasible-set discrepancy cho omissions và over-constraints;
3. solver-checkable counterexample;
4. explicit inconclusive states và detection–cost evaluation;
5. audited benchmark/annotation và robust statistical protocol.

Không đưa repair và calibrated abstention vào main contribution. Chúng có thể là future work sau khi evaluator đã được chứng minh đáng tin cậy.

Tài liệu tham khảo

Li, H. and M. Hai (2026). “Falsification-Based Verification of LLM-Generated Optimization Models: Sound Test Batteries and Their Detection Limits”. In: *arXiv preprint arXiv:2607.16646*. DOI: [10.48550/arXiv.2607.16646](https://doi.org/10.48550/arXiv.2607.16646). URL: <https://arxiv.org/abs/2607.16646>.

- Li, Z., Z. Guo, X. Lu, J. Wang, J. Song, C. Shen, J. Wu, and M. Sun (2026a). “OptArgus: A Multi-Agent System to Detect Hallucinations in LLM-Based Optimization Modeling”. In: *arXiv preprint arXiv:2605.11738*. DOI: [10.48550/arXiv.2605.11738](https://arxiv.org/abs/2605.11738). URL: <https://arxiv.org/abs/2605.11738>.
- Li, Z., H. Lu, T. Wei, Y. Chen, W. Liu, Y. Lan, F. Zhang, and Z. Wen (2026b). “Constructing Industrial-Scale Optimization Modeling Benchmark”. In: *Proceedings of the 43rd International Conference on Machine Learning*. DOI: [10.48550/arXiv.2602.10450](https://arxiv.org/abs/2602.10450). URL: <https://arxiv.org/abs/2602.10450>.
- Lian, J. J., Y. Sun, H. Chen, C. Zhang, and C.-P. Teo (2026). “ReLoop: Structured Modeling and Behavioral Verification for Reliable LLM-Based Optimization”. In: *arXiv preprint arXiv:2602.15983*. DOI: [10.48550/arXiv.2602.15983](https://arxiv.org/abs/2602.15983). URL: <https://arxiv.org/abs/2602.15983>.
- Lyu, Z., S. Hu, L. Liu, H. Yang, and M. Li (2026). “Canonical Intermediate Representation for LLM-Based Optimization Problem Formulation and Code Generation”. In: *arXiv preprint arXiv:2602.02029*. DOI: [10.48550/arXiv.2602.02029](https://arxiv.org/abs/2602.02029). URL: <https://arxiv.org/abs/2602.02029>.
- Rahman, S. A., S. A. A. Cuellar, G. Raissov, and M. Raza (2026). “VeriSimpl: Robust Optimization Modeling from Natural Language using Simplification-Based Verification”. In: *Proceedings of the 43rd International Conference on Machine Learning*. URL: <https://arxiv.org/abs/2607.20474>.
- Refai, D. and M. Ahmed (2025). “Peering Inside the Black Box: Uncovering LLM Errors in Optimization Modelling through Component-Level Evaluation”. In: *arXiv preprint arXiv:2510.16943*. DOI: [10.48550/arXiv.2510.16943](https://arxiv.org/abs/2510.16943). URL: <https://arxiv.org/abs/2510.16943>.
- Xiao, Z., J. Xie, L. Xu, S. Guan, J. Zhu, X. Han, X. Fu, W. Yu, H. Wu, W. Shi, Q. Kang, J. Duan, T. Zhong, M. Yuan, J. Zeng, Y. Wang, G. Chen, and D. Zhang (2025). “A Survey of Optimization Modeling Meets LLMs: Progress and Future Directions”. In: *arXiv preprint arXiv:2508.10047*. DOI: [10.48550/arXiv.2508.10047](https://arxiv.org/abs/2508.10047). URL: <https://arxiv.org/abs/2508.10047>.
- Zadorojniy, A., S. Wasserkrug, and E. Farchi (2025). “An Agent-Based Framework for the Automatic Validation of Mathematical Optimization Models”. In: *arXiv preprint arXiv:2511.16383*. DOI: [10.48550/arXiv.2511.16383](https://arxiv.org/abs/2511.16383). URL: <https://arxiv.org/abs/2511.16383>.
- Zhai, H., C. Lawless, E. Vitercik, and L. Leqi (2025). “EquivaMap: Leveraging LLMs for Automatic Equivalence Checking of Optimization Formulations”. In: *arXiv preprint arXiv:2502.14760*. DOI: [10.48550/arXiv.2502.14760](https://arxiv.org/abs/2502.14760). URL: <https://arxiv.org/abs/2502.14760>.